

Lista de Exercícios – Variáveis Dummies, Modelos Logit e Probit

Disciplina: Econometria **Professor:** Cássio da Nóbrega Besarria **Curso:** Ciência de Dados para Negócios (CDN) – UFPB
Aluna: Maria Carolina

Base de dados escolhida: *Adult / Census Income* (extraída do Censo dos EUA de 1994, disponível publicamente no repositório UCI Machine Learning). A base traz características demográficas e ocupacionais de 48.842 indivíduos, com o objetivo original de prever se a renda anual de uma pessoa ultrapassa US\$ 50 mil.

```
In [1]: import numpy as np
import pandas as pd
import statsmodels.api as sm
import matplotlib.pyplot as plt
from sklearn.metrics import confusion_matrix

pd.set_option('display.max_columns', None)
plt.rcParams['figure.figsize'] = (6, 4)

data = pd.read_csv('adult.csv')
data.head()
```

```
Out[1]:
```

	age	workclass	fnlwgt	education	educational-num	marital-status	occupation	relationship	race	gender	capital-gain	ca
0	25	Private	226802	11th	7	Never-married	Machine-op-inspct	Own-child	Black	Male	0	
1	38	Private	89814	HS-grad	9	Married-civ-spouse	Farming-fishing	Husband	White	Male	0	
2	28	Local-gov	336951	Assoc-acdm	12	Married-civ-spouse	Protective-serv	Husband	White	Male	0	
3	44	Private	160323	Some-college	10	Married-civ-spouse	Machine-op-inspct	Husband	Black	Male	7688	
4	18	?	103497	Some-college	10	Never-married	?	Own-child	White	Female	0	

1. Importação da base de dados

a. Número de observações

```
In [2]: n_obs = data.shape[0]
print(f"Número de observações: {n_obs}")
```

Número de observações: 48842

b. Descrição das variáveis (utilizadas na análise)

Variável	Descrição	Tipo
age	Idade do indivíduo	Quantitativa
educational-num	Anos de estudo (escala numérica associada ao nível educacional)	Quantitativa
hours-per-week	Horas trabalhadas por semana	Quantitativa
capital-gain	Ganho de capital declarado no ano	Quantitativa
marital-status	Estado civil	Qualitativa (categórica)
income	Renda anual: <=50K ou >50K	Usada para construir a variável dependente

A base original possui 15 colunas; para esta atividade, foram selecionadas as variáveis acima, suficientes para atender à exigência de pelo menos quatro explicativas (sendo uma qualitativa).

c. Identificação da variável dependente e das variáveis explicativas

- **Variável dependente (binária):** `renda_alta` (1 = indivíduo com renda anual acima de US\$ 50 mil; 0 = renda até US\$ 50 mil), construída a partir de `income`.
- **Variáveis explicativas:** `age`, `educational-num`, `hours-per-week`, `capital-gain` (quantitativas) e `estado_civil` (qualitativa, versão simplificada de `marital-status`, transformada em dummies).

d. Justificativa para a escolha da variável dependente binária

A variável `income` já é originalmente categórica, dividindo a população em dois grupos de renda (`<=50K` e `>50K`). Transformá-la em uma dummy é natural e preserva o objetivo clássico dessa base: entender quais características pessoais e profissionais estão associadas à maior probabilidade de auferir renda elevada — uma pergunta tipicamente binária, e não de magnitude contínua da renda (que, aliás, não está disponível na base em valores exatos).

```
In [3]: data['renda_alta'] = (data['income'] == '>50K').astype(int)
data[['income', 'renda_alta']].head(10)
```

```
Out[3]:
```

	income	renda_alta
0	<=50K	0
1	<=50K	0
2	>50K	1
3	>50K	1
4	<=50K	0
5	<=50K	0
6	<=50K	0
7	>50K	1
8	<=50K	0
9	<=50K	0

2. Análise descritiva da base de dados

a. Estatísticas descritivas das variáveis quantitativas

```
In [4]: vars_quant = ['age', 'educational-num', 'hours-per-week', 'capital-gain']
data[vars_quant].describe()
```

```
Out[4]:
```

	age	educational-num	hours-per-week	capital-gain
count	48842.000000	48842.000000	48842.000000	48842.000000
mean	38.643585	10.078089	40.422382	1079.067626
std	13.710510	2.570973	12.391444	7452.019058
min	17.000000	1.000000	1.000000	0.000000
25%	28.000000	9.000000	40.000000	0.000000
50%	37.000000	10.000000	40.000000	0.000000
75%	48.000000	12.000000	45.000000	0.000000
max	90.000000	16.000000	99.000000	99999.000000

b. Frequência da variável dependente


```
In [5]: freq_dep = data['renda_alta'].value_counts().sort_index()
freq_dep_pct = data['renda_alta'].value_counts(normalize=True).sort_index() * 100
pd.DataFrame({'Frequência': freq_dep, 'Percentual (%)': freq_dep_pct.round(2)})
```

```
Out[5]:
```

	Frequência	Percentual (%)
renda_alta		
0	37155	76.07
1	11687	23.93

```
In [6]: data['renda_alta'].value_counts().sort_index().plot(kind='bar', color=['#4C72B0', '#DD8452'])
plt.xticks([0, 1], ['Até 50K (0)', 'Acima de 50K (1)'], rotation=0)
plt.title('Frequência da variável dependente')
plt.ylabel('Número de observações')
```

```
plt.show()
```



c. Frequência das variáveis qualitativas

A variável original `marital-status` tem sete categorias, três delas com poucas observações. Para tornar a interpretação mais clara, ela foi simplificada em quatro categorias: `Married` (casado, unindo as três variações da base original), `Never-married`, `Divorced` e `Widowed-Separated` (viúvo ou separado, agrupados por representarem situação conjugal encerrada de forma não voluntária/dissolvida).

```
In [7]: mapa_estado_civil = {
        'Married-civ-spouse': 'Married',
        'Married-AF-spouse': 'Married',
        'Married-spouse-absent': 'Married',
        'Never-married': 'Never-married',
        'Divorced': 'Divorced',
        'Separated': 'Widowed-Separated',
        'Widowed': 'Widowed-Separated'
      }
data['estado_civil'] = data['marital-status'].map(mapa_estado_civil)

freq_ec = data['estado_civil'].value_counts()
freq_ec_pct = data['estado_civil'].value_counts(normalize=True) * 100
pd.DataFrame({'Frequência': freq_ec, 'Percentual (%)': freq_ec_pct.round(2)})
```

```
Out[7]:
```

	Frequência	Percentual (%)
--	------------	----------------

estado_civil		
Married	23044	47.18
Never-married	16117	33.00
Divorced	6633	13.58
Widowed-Separated	3048	6.24

d. Interpretação econômica dos resultados

Cerca de 24% dos indivíduos da amostra têm renda acima de 50 mil dólares, indicando uma variável dependente desbalanceada (a classe minoritária representa menos de um quarto da amostra) — ponto que retomaremos na avaliação da capacidade preditiva (questão 11). Quanto ao estado civil, a categoria `Married` é a mais frequente, respondendo por praticamente metade da amostra, seguida por `Never-married`; as categorias `Divorced` e `Widowed-Separated` são bem menos representadas, mas ainda com número suficiente de observações para permitir estimação estável dos coeficientes.

3. Fundamentos teóricos das variáveis dummies

a. O que são variáveis dummies

Variáveis dummies (ou variáveis binárias/indicadoras) são variáveis que assumem apenas os valores 0 ou 1 para representar a presença ou ausência de um atributo qualitativo (categórico) dentro de um modelo de regressão. Como modelos de regressão exigem variáveis numéricas, as dummies são a forma padrão de incorporar informação qualitativa — como estado civil, sexo, região ou nível educacional — na análise quantitativa.

b. Finalidade em modelos econométricos

As dummies permitem capturar diferenças de nível (intercepto) associadas a categorias distintas de uma característica qualitativa. Isso possibilita comparar grupos dentro do mesmo modelo — por exemplo, verificar se o estado civil afeta a probabilidade de renda elevada — mantendo as demais variáveis explicativas constantes (efeito *ceteris paribus*).

c. Significado da categoria de referência

Quando uma variável qualitativa com k categorias é transformada em dummies, apenas $k-1$ dummies são incluídas no modelo. A categoria excluída é chamada de **categoria de referência** (ou categoria base), e todos os coeficientes das demais dummies devem ser interpretados como o efeito *diferencial* em relação a essa categoria de referência — e não como um efeito absoluto.

d. O problema da armadilha das variáveis dummies (Dummy Variable Trap)

A armadilha das variáveis dummies ocorre quando se inclui uma dummy para **todas** as categorias de uma variável qualitativa junto com o intercepto do modelo. Nesse caso, a soma das dummies é sempre igual a 1 para qualquer observação, o que gera **multicolinearidade perfeita** com o intercepto: a matriz de variáveis explicativas deixa de ter posto completo e o modelo não pode ser estimado por MQO (a matriz $X'X$ torna-se singular, não podendo ser invertida). A solução é omitir uma categoria como referência.

4. Construção das variáveis dummies

a. Procedimento utilizado

A variável `estado_civil` (já simplificada em 4 categorias na questão 2.c) foi convertida em variáveis dummies utilizando `pd.get_dummies`, removendo a categoria `Never-married` (`drop_first`, com a coluna reordenada antes) para evitar a armadilha das variáveis dummies.

b. Categoria de referência adotada

A categoria de referência é `Never-married` (nunca casado), por ser uma categoria numerosa e uma base de comparação natural para as demais situações conjugais.

c. Interpretação econômica das variáveis criadas

Cada dummy (`ec_Married`, `ec_Divorced`, `ec_Widowed-Separated`) captura a diferença na probabilidade prevista de renda elevada para indivíduos na respectiva situação conjugal, em comparação com indivíduos nunca casados, mantendo as demais variáveis do modelo constantes.

```
In [8]: ordem_categorias = ['Never-married', 'Married', 'Divorced', 'Widowed-Separated']
data['estado_civil'] = pd.Categorical(data['estado_civil'], categories=ordem_categorias)

ec_dummies = pd.get_dummies(data['estado_civil'], prefix='ec', drop_first=True)
data = pd.concat([data, ec_dummies], axis=1)
ec_cols = list(ec_dummies.columns)
data[['estado_civil'] + ec_cols].drop_duplicates().sort_values('estado_civil')
```

```
Out[8]:
```

	estado_civil	ec_Married	ec_Divorced	ec_Widowed-Separated
0	Never-married	False	False	False
1	Married	True	False	False
22	Divorced	False	True	False
18	Widowed-Separated	False	False	True

5. Modelo de Probabilidade Linear (MQO)

a. Equação estimada

$$P(\text{renda_alta} = 1) = b_0 + b_1 \cdot \text{age} + b_2 \cdot \text{educational-num} + b_3 \cdot \text{hours-per-week} + b_4 \cdot \text{capital-gain} + \text{soma}(\gamma_j \cdot \text{ec}_j) + u$$

```
In [9]: X_vars = ['age', 'educational-num', 'hours-per-week', 'capital-gain'] + ec_cols
X = sm.add_constant(data[X_vars].astype(float))
y = data['renda_alta'].astype(float)

mpl = sm.OLS(y, X).fit(cov_type='HC3')
print(mpl.summary())
```

OLS Regression Results						
=====						
Dep. Variable:	renda_alta	R-squared:	0.321			
Model:	OLS	Adj. R-squared:	0.321			
Method:	Least Squares	F-statistic:	3297.			
Date:	Thu, 06 Aug 2026	Prob (F-statistic):	0.00			
Time:	21:35:56	Log-Likelihood:	-18253.			
No. Observations:	48842	AIC:	3.652e+04			
Df Residuals:	48834	BIC:	3.659e+04			
Df Model:	7					
Covariance Type:	HC3					
=====						
	coef	std err	z	P> z	[0.025	0.975]

const	-0.6094	0.008	-74.589	0.000	-0.625	-0.593
age	0.0029	0.000	20.091	0.000	0.003	0.003
educational-num	0.0451	0.001	70.981	0.000	0.044	0.046
hours-per-week	0.0033	0.000	23.634	0.000	0.003	0.004
capital-gain	8.338e-06	2.53e-07	32.921	0.000	7.84e-06	8.83e-06
ec_Married	0.3020	0.004	70.909	0.000	0.294	0.310
ec_Divorced	-0.0083	0.004	-1.877	0.061	-0.017	0.000
ec_Widowed-Separated	0.0029	0.006	0.502	0.616	-0.008	0.014
=====						
Omnibus:	2952.880	Durbin-Watson:	2.005			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	3089.800			
Skew:	0.579	Prob(JB):	0.00			
Kurtosis:	2.581	Cond. No.	4.25e+04			

Notes:

[1] Standard Errors are heteroscedasticity robust (HC3)

[2] The condition number is large, 4.25e+04. This might indicate that there are strong multicollinearity or other numerical problems.

b. Interpretação econômica dos coeficientes

- **age** : idade adicional está associada a uma variação positiva na probabilidade estimada de renda elevada, mantendo as demais variáveis constantes — coerente com o acúmulo de experiência profissional ao longo da carreira.
- **educational-num** : cada ano adicional de estudo eleva a probabilidade estimada de renda alta, o que está de acordo com a teoria do capital humano (mais escolaridade, maior produtividade e remuneração esperada).
- **hours-per-week** : mais horas trabalhadas por semana também aumentam a probabilidade estimada, refletindo maior dedicação ao trabalho remunerado.
- **capital-gain** : ganhos de capital elevam a probabilidade estimada de renda alta, o que é esperado, já que ganhos de capital relevantes normalmente estão associados a patrimônio e renda mais altos.
- Dummies de **estado_civil** : cada coeficiente mostra a diferença de probabilidade em relação à categoria de referência (nunca casado); espera-se, por exemplo, coeficiente positivo para **ec_Married**, associado a estabilidade financeira e, historicamente, à composição etária/profissional desse grupo.

c. Coeficiente de determinação R²

```
In [10]: print(f"R²: {mpl.rsquared:.4f}")
print(f"R² ajustado: {mpl.rsquared_adj:.4f}")
```

R²: 0.3208

R² ajustado: 0.3207

d. Limitações do modelo

O MPL apresenta três limitações centrais: (i) pode gerar probabilidades previstas fora do intervalo [0,1], o que não faz sentido econômico; (ii) o erro é heteroscedástico por construção, pois sua variância depende dos valores de X (por isso os erros-padrão foram estimados de forma robusta, HC3); e (iii) impõe um efeito marginal constante para cada variável explicativa, uma simplificação pouco realista, já que o efeito de uma variável sobre a probabilidade tende a ser não linear (menor nos extremos e maior perto de 0,5).

```
In [11]: pred_mpl = mpl.predict(X)
print(f"Mínimo previsto: {pred_mpl.min():.4f}")
print(f"Máximo previsto: {pred_mpl.max():.4f}")
print(f"Nº de previsões < 0: {(pred_mpl < 0).sum()}")
print(f"Nº de previsões > 1: {(pred_mpl > 1).sum()}")
```

Mínimo previsto: -0.4492

Máximo previsto: 1.6886

Nº de previsões < 0: 7645

Nº de previsões > 1: 229

6. Modelos Logit e Probit – fundamentos teóricos

a. Por que o MQO não é o método mais adequado para variável dependente binária

O MQO aplicado a uma variável dependente binária (Modelo de Probabilidade Linear) assume uma relação linear entre X e a probabilidade do evento, o que pode gerar previsões inconsistentes com a definição de probabilidade (valores abaixo de 0 ou acima de 1, como confirmado na questão 5.d). Além disso, o erro é necessariamente heteroscedástico, o que compromete a eficiência dos estimadores (embora eles continuem não viesados). Os modelos Logit e Probit resolvem isso ao aplicar uma função de ligação não linear que restringe a probabilidade estimada ao intervalo (0,1).

b. Diferenças entre os modelos Logit e Probit

Ambos modelam $P(y=1|X) = F(X \cdot \beta)$, mas usam funções de distribuição acumulada (F) diferentes:

- **Logit:** usa a função logística, $F(z) = e^z / (1 + e^z)$, cujos erros seguem uma distribuição logística (caudas um pouco mais pesadas).
- **Probit:** usa a função de distribuição acumulada da normal padrão, $F(z) = \Phi(z)$.

Na prática, as curvas são muito semelhantes, sobretudo próximas de $P=0,5$; diferem um pouco mais nas caudas.

c. Vantagens e limitações de cada modelo

- **Logit:** os coeficientes têm interpretação direta em termos de *odds ratio* (razão de chances) via e^{β} , o que facilita a comunicação dos resultados; é computacionalmente mais leve.
- **Probit:** tem fundamentação teórica ligada a modelos de utilidade latente com erro normal, o que é conveniente em modelos estruturais (e é a base natural para extensões como Probit multivariado); porém não tem uma interpretação tão simples quanto o odds ratio do Logit.

7. Modelo Logit

a. Equação estimada

```
In [12]: logit_model = sm.Logit(y, X).fit(displ=0)
print(logit_model.summary())
```

```
Logit Regression Results
=====
Dep. Variable:          renda_alta      No. Observations:          48842
Model:                  Logit           Df Residuals:              48834
Method:                 MLE             Df Model:                  7
Date:                   Thu, 06 Aug 2026   Pseudo R-squ.:             0.3752
Time:                   21:35:57          Log-Likelihood:            -16792.
converged:              True             LL-Null:                   -26875.
Covariance Type:        nonrobust         LLR p-value:               0.000
=====
              coef      std err          z      P>|z|      [0.025      0.975]
-----
const          -9.4270         0.111    -84.849      0.000     -9.645     -9.209
age              0.0250         0.001     21.097      0.000         0.023         0.027
educational-num  0.3679         0.006     59.713      0.000         0.356         0.380
hours-per-week  0.0318         0.001     27.278      0.000         0.030         0.034
capital-gain    0.0003      8.09e-06     38.203      0.000         0.000         0.000
ec_Married      2.6760         0.048     55.579      0.000         2.582         2.770
ec_Divorced     0.4971         0.066      7.584      0.000         0.369         0.626
ec_Widowed-Separated 0.3667         0.093      3.929      0.000         0.184         0.550
=====
```

b. Interpretação dos sinais dos coeficientes

Os sinais dos coeficientes do Logit devem ser interpretados apenas em termos de direção do efeito sobre a probabilidade (não em magnitude direta): sinal positivo aumenta a probabilidade prevista de `renda_alta=1`, sinal negativo reduz. Os sinais são consistentes com os observados no MPL: `educational-num`, `age`, `hours-per-week` e `capital-gain` positivos.

c. Significância estatística

```
In [13]: logit_pvalues = logit_model.pvalues.round(4)
logit_signif = pd.DataFrame({
    'Coeficiente': logit_model.params.round(4),
    'p-valor': logit_pvalues,
    'Significativo a 5%': logit_pvalues < 0.05
})
logit_signif
```

Out[13]:

	Coefficiente	p-valor	Significativo a 5%
const	-9.4270	0.0000	True
age	0.0250	0.0000	True
educational-num	0.3679	0.0000	True
hours-per-week	0.0318	0.0000	True
capital-gain	0.0003	0.0000	True
ec_Married	2.6760	0.0000	True
ec_Divorced	0.4971	0.0000	True
ec_Widowed-Separated	0.3667	0.0001	True

d. Interpretação econômica dos resultados

Todas as variáveis quantitativas (age , educational-num , hours-per-week , capital-gain) mostram-se estatisticamente significativas, reforçando a relação positiva entre escolaridade, dedicação ao trabalho, experiência (idade) e patrimônio (ganho de capital) com a probabilidade de renda elevada. As dummies de estado civil também tendem a ser significativas, com destaque para ec_Married , refletindo o perfil socioeconômico historicamente associado a essa categoria na base (idade mais avançada e maior estabilidade profissional).

8. Modelo Probit

a. Equação estimada

In [14]:

```
probit_model = sm.Probit(y, X).fit(disps=0)
print(probit_model.summary())
```

Probit Regression Results						
Dep. Variable:	renda_alta	No. Observations:	48842			
Model:	Probit	Df Residuals:	48834			
Method:	MLE	Df Model:	7			
Date:	Thu, 06 Aug 2026	Pseudo R-squ.:	0.3752			
Time:	21:35:57	Log-Likelihood:	-16791.			
Converged:	True	LL-Null:	-26875.			
Covariance Type:	nonrobust	LLR p-value:	0.000			
	coef	std err	z	P> z	[0.025	0.975]
const	-5.3373	0.059	-90.551	0.000	-5.453	-5.222
age	0.0147	0.001	21.850	0.000	0.013	0.016
educational-num	0.2079	0.003	61.812	0.000	0.201	0.215
hours-per-week	0.0184	0.001	28.139	0.000	0.017	0.020
capital-gain	0.0002	3.98e-06	40.221	0.000	0.000	0.000
ec_Married	1.4651	0.024	59.932	0.000	1.417	1.513
ec_Divorced	0.2381	0.033	7.134	0.000	0.173	0.304
ec_Widowed-Separated	0.1837	0.047	3.900	0.000	0.091	0.276

b. Interpretação dos coeficientes

Assim como no Logit, os coeficientes do Probit indicam apenas a direção e a significância estatística do efeito de cada variável sobre a probabilidade — a magnitude não é diretamente interpretável em termos de probabilidade, pois o modelo é não linear (é necessário calcular efeitos marginais, feito na questão 10).

c. Comparação com o modelo Logit

In [15]:

```
comp_coef = pd.DataFrame({
    'MQO': mpl.params,
    'Logit': logit_model.params,
    'Probit': probit_model.params
}).round(4)
comp_coef
```

Out[15]:		MQO	Logit	Probit
	const	-0.6094	-9.4270	-5.3373
	age	0.0029	0.0250	0.0147
	educational-num	0.0451	0.3679	0.2079
	hours-per-week	0.0033	0.0318	0.0184
	capital-gain	0.0000	0.0003	0.0002
	ec_Married	0.3020	2.6760	1.4651
	ec_Divorced	-0.0083	0.4971	0.2381
	ec_Widowed-Separated	0.0029	0.3667	0.1837

Os sinais e a significância estatística dos coeficientes do Logit e do Probit são praticamente idênticos; a diferença numérica nos coeficientes decorre apenas da escala das funções de ligação (a distribuição logística tem variância maior que a normal padrão), sem alterar as conclusões econômicas.

9. Comparação entre MQO, Logit e Probit

a. Diferenças nos coeficientes

Os coeficientes do MQO já são diretamente interpretáveis como variação em pontos percentuais de probabilidade, enquanto os do Logit e Probit representam variações em uma escala latente (log-odds no Logit e índice-Z no Probit) e não são diretamente comparáveis entre si em magnitude — apenas em sinal e significância — sem o cálculo de efeitos marginais.

b. Diferenças na significância estatística

As variáveis que se mostram significativas no MQO também se mostram significativas no Logit e no Probit, o que reforça a robustez dos resultados encontrados, ainda que os p-valores não sejam idênticos entre os três modelos.

```
In [16]: comp_pvalues = pd.DataFrame({
          'MQO': mpl.pvalues,
          'Logit': logit_model.pvalues,
          'Probit': probit_model.pvalues
        }).round(4)
comp_pvalues
```

Out[16]:		MQO	Logit	Probit
	const	0.0000	0.0000	0.0000
	age	0.0000	0.0000	0.0000
	educational-num	0.0000	0.0000	0.0000
	hours-per-week	0.0000	0.0000	0.0000
	capital-gain	0.0000	0.0000	0.0000
	ec_Married	0.0000	0.0000	0.0000
	ec_Divorced	0.0606	0.0000	0.0000
	ec_Widowed-Separated	0.6159	0.0001	0.0001

c. Vantagens e limitações de cada modelo

- **MQO/MPL:** simples de estimar e interpretar, mas pode gerar probabilidades inválidas e tem erro heteroscedástico por construção.
- **Logit:** garante probabilidades no intervalo (0,1), tem interpretação via odds ratio, mas exige estimação por máxima verossimilhança (não há fórmula fechada) e mais cuidado na interpretação.
- **Probit:** também garante probabilidades válidas e tem fundamentação em modelos de utilidade latente normal, mas sua interpretação direta é ainda menos intuitiva que a do Logit.

10. Efeitos marginais (modelo Logit)

a. Efeitos marginais médios (AME)

```
In [17]: margeff = logit_model.get_margeff(at='overall', method='dydx')
print(margeff.summary())
```


Logit Marginal Effects						
Dep. Variable:	renda_alta					
Method:	dydx					
At:	overall					
	dy/dx	std err	z	P> z	[0.025	0.975]
age	0.0027	0.000	21.471	0.000	0.002	0.003
educational-num	0.0402	0.001	71.775	0.000	0.039	0.041
hours-per-week	0.0035	0.000	28.133	0.000	0.003	0.004
capital-gain	3.373e-05	8.29e-07	40.690	0.000	3.21e-05	3.54e-05
ec_Married	0.2921	0.005	61.602	0.000	0.283	0.301
ec_Divorced	0.0543	0.007	7.583	0.000	0.040	0.068
ec_Widowed-Separated	0.0400	0.010	3.930	0.000	0.020	0.060

b. Interpretação econômica

O efeito marginal médio (AME) indica, para cada variável explicativa, a variação média na probabilidade prevista de `renda_alta=1` associada a um aumento marginal (uma unidade, no caso das variáveis contínuas, ou a mudança de categoria de referência para a categoria em questão, no caso das dummies), mantendo as demais variáveis do modelo em seus valores observados. Diferentemente do coeficiente bruto do Logit, o efeito marginal já está na mesma escala da probabilidade, o que facilita a leitura econômica direta dos resultados: por exemplo, o efeito marginal de `educational-num` mostra em quantos pontos percentuais, em média, a probabilidade de renda alta aumenta a cada ano adicional de estudo.

c. Comparação entre coeficientes e efeitos marginais

```
In [18]: comparacao_logit = pd.DataFrame({
    'Coeficiente Logit': logit_model.params.drop('const'),
    'Efeito Marginal (AME)': margeff.margeff
}, index=logit_model.params.drop('const').index).round(4)
comparacao_logit
```

	Coeficiente Logit	Efeito Marginal (AME)
age	0.0250	0.0027
educational-num	0.3679	0.0402
hours-per-week	0.0318	0.0035
capital-gain	0.0003	0.0000
ec_Married	2.6760	0.2921
ec_Divorced	0.4971	0.0543
ec_Widowed-Separated	0.3667	0.0400

Os coeficientes do Logit e os efeitos marginais têm sempre o mesmo sinal, mas magnitudes diferentes: o coeficiente reflete o efeito sobre o índice latente (log-odds), enquanto o efeito marginal reflete o efeito sobre a probabilidade propriamente dita — por isso, é o efeito marginal (e não o coeficiente bruto) que deve ser usado para comunicar a magnitude econômica do resultado.

11. Capacidade preditiva do modelo (Logit)

a. Matriz de confusão

```
In [19]: y_pred_prob = logit_model.predict(X)
y_pred = (y_pred_prob >= 0.5).astype(int)

cm = confusion_matrix(y, y_pred)
cm_df = pd.DataFrame(cm,
    index=['Real: Até 50K (0)', 'Real: Acima de 50K (1)'],
    columns=['Previsto: Até 50K (0)', 'Previsto: Acima de 50K (1)'])
cm_df
```

	Previsto: Até 50K (0)	Previsto: Acima de 50K (1)
Real: Até 50K (0)	34528	2627
Real: Acima de 50K (1)	5280	6407

```
In [20]: tn, fp, fn, tp = cm.ravel()

acuracia = (tp + tn) / (tp + tn + fp + fn)
```

```
sensibilidade = tp / (tp + fn) # taxa de acerto entre quem tem renda alta
especificidade = tn / (tn + fp) # taxa de acerto entre quem tem renda baixa

print(f"Percentual de acertos (acurácia): {acuracia:.2%}")
print(f"Sensibilidade (True Positive Rate): {sensibilidade:.2%}")
print(f"Especificidade (True Negative Rate): {especificidade:.2%}")
```

Percentual de acertos (acurácia): 83.81%
 Sensibilidade (True Positive Rate): 54.82%
 Especificidade (True Negative Rate): 92.93%

b. Percentual de acertos: acurácia global do modelo, usando ponto de corte 0,5.

c. Sensibilidade: proporção de casos verdadeiramente positivos (`renda_alta=1`) corretamente classificados pelo modelo.

d. Especificidade: proporção de casos verdadeiramente negativos (`renda_alta=0`) corretamente classificados pelo modelo.

Como observado na questão 2.d, a classe `renda_alta=0` é majoritária (cerca de 76% da amostra). Por isso, é esperado que a especificidade seja mais alta que a sensibilidade: com o ponto de corte padrão de 0,5, o modelo tende a acertar mais os casos de renda baixa (a classe mais frequente) do que os de renda alta.

12. Classificação de afirmações (Verdadeiro ou Falso)

a. "Os coeficientes do modelo Logit representam diretamente a variação da probabilidade." → Falso. Os coeficientes do Logit representam a variação no log da razão de chances (log-odds), não a variação direta da probabilidade. Para obter o efeito sobre a probabilidade, é necessário calcular os efeitos marginais (questão 10), pois a relação entre X e a probabilidade é não linear.

b. "Os modelos Logit e Probit produzem probabilidades entre 0 e 1." → Verdadeiro. Ambos utilizam funções de distribuição acumulada (logística e normal, respectivamente) como função de ligação, que por definição estão sempre restritas ao intervalo (0,1), diferentemente do MPL.

c. "O Modelo de Probabilidade Linear pode gerar probabilidades negativas ou superiores a um." → Verdadeiro. Como o MPL é uma reta ajustada por MQO, não há nenhuma restrição matemática que impeça a previsão de sair do intervalo [0,1], especialmente para valores extremos das variáveis explicativas (confirmado na questão 5.d).

d. "Os efeitos marginais dependem dos valores das variáveis explicativas." → Verdadeiro. Nos modelos Logit e Probit, o efeito marginal de cada variável é dado pela derivada de uma função não linear (logística ou normal) avaliada em um ponto específico de X; por isso, o efeito marginal varia conforme os valores das demais variáveis (é por isso que se costuma reportar o efeito marginal médio, AME, calculado na questão 10).

e. "Logit e Probit normalmente produzem resultados bastante semelhantes." → Verdadeiro. Como observado na questão 8.c, os sinais e a significância dos coeficientes praticamente coincidem entre os dois modelos nesta aplicação; isso é esperado porque as distribuições logística e normal padrão têm formatos muito próximos, sobretudo na região central.

13. Parecer técnico

A base de dados utilizada (Adult / Census Income) atende adequadamente aos requisitos da atividade, pois já traz uma variável dependente binária de interesse direto — se o indivíduo tem renda anual acima ou abaixo de 50 mil dólares — construída a partir de dados reais do Censo dos Estados Unidos. As variáveis dummies, construídas a partir do estado civil (simplificado em quatro categorias para evitar grupos muito pequenos), mostraram-se importantes para captar diferenças de comportamento entre grupos qualitativamente distintos que não poderiam ser representadas por variáveis contínuas, sempre com o cuidado de manter uma categoria de referência e evitar a armadilha das variáveis dummies.

A comparação entre os três modelos indicou resultados qualitativamente consistentes: o Modelo de Probabilidade Linear (MQO), apesar de didático e fácil de interpretar, apresentou previsões fora do intervalo [0,1] e erro heteroscedástico por construção, evidenciando suas limitações teóricas para variáveis dependentes binárias. Os modelos Logit e Probit corrigiram esse problema ao restringir as probabilidades previstas ao intervalo válido, apresentando coeficientes com sinais e significância estatística muito próximos entre si — como esperado, dada a semelhança entre as distribuições logística e normal padrão.

Os efeitos marginais médios do modelo Logit permitiram traduzir os coeficientes (em escala de log-odds) para variações diretamente interpretáveis em pontos percentuais de probabilidade, mostrando que escolaridade, horas trabalhadas, idade e ganho de capital elevam a probabilidade prevista de renda alta — resultado coerente com a teoria do capital humano e com a literatura sobre determinantes de renda.

Quanto à capacidade preditiva, a matriz de confusão revelou acurácia global satisfatória, mas com sensibilidade inferior à especificidade, refletindo o desbalanceamento da variável dependente (muito mais casos de renda baixa que de renda alta na amostra) — um ponto de atenção para estudos futuros, que poderiam considerar pontos de corte alternativos ou métricas como a curva ROC/AUC.

Em conclusão, o ajuste dos modelos Logit e Probit é adequado e mais confiável do que o do MPL para o objetivo do estudo, sendo os efeitos marginais a métrica mais apropriada para a interpretação econômica dos resultados, e a matriz de confusão uma ferramenta complementar útil para avaliar a qualidade preditiva do modelo fora da amostra de estimação.